



西南交通大学学报  
*Journal of Southwest Jiaotong University*  
ISSN 0258-2724, CN 51-1277/U

## 《西南交通大学学报》网络首发论文

题目: 基于手机传感器运动行为识别的车辆轨迹实时在线压缩方法  
作者: 赵东保, 冯林林, 邓悦, 曹连海  
网络首发日期: 2021-09-09  
引用格式: 赵东保, 冯林林, 邓悦, 曹连海. 基于手机传感器运动行为识别的车辆轨迹实时在线压缩方法. 西南交通大学学报.  
<https://kns.cnki.net/kcms/detail/51.1277.u.20210909.1545.003.html>



**网络首发:** 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

**出版确认:** 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

DOI: 10.3969/j.issn.0258-2724.20210136

# 基于手机传感器运动行为识别的车辆轨迹实时在线压缩方法

赵东保, 冯林林, 邓悦, 曹连海

(华北水利水电大学测绘与地理信息学院, 河南郑州, 450046)

**摘要:** 随着具有定位功能的各类便携式移动设备的普及, 产生了大量的移动目标时空轨迹数据, 庞大的数据规模对轨迹数据管理和分析带来了严峻的挑战。为此, 提出了一种基于车辆运动行为识别的车辆时空轨迹数据压缩算法。该算法通过监测分析车辆在不同运动行为模式下智能手机内置线性加速度传感器和方向传感器的数据变化规律, 识别车辆的转向行为和变速行为, 并根据识别结果请求 GPS 传感器定位, 记录相应轨迹特征点, 从而实现车辆轨迹的实时在线压缩。将本文算法与基于特征点提取的轨迹压缩的代表性算法进行对比实验, 结果表明: 本文算法在压缩精度上稍弱于代表性算法, 但其可以在线对轨迹数据进行压缩, 实时性强, 计算效率高, 减少了网络传输数据量; 只在关键特征点处请求定位采样, 压缩结果能一定程度地适应路况变化, 减少了对手机存储空间占用, 并有助于降低手机耗电量。

**关键词:** 轨迹压缩; 手机传感器; 运动行为模式; 轨迹特征点

## Real-time Online Compression Method for Vehicle Trajectory Data Based on Pattern Recognition of Motion Behavior by Smart Phone Sensors

ZHAO Dongbao, FENG Linlin, DENG Yue, CAO Lianhai

(College of Surveying and Geo-informatics, North China University of Water Resources and Electric Power, Zhengzhou 450046, China)

**Abstract:** Popularization of various portable mobile devices with positioning function produces massive spatial-temporal trajectory data of moving objects, and the huge data scale has brought severe challenges to trajectory data management and analysis. Therefore, a spatial-temporal trajectory data compression algorithm based on the pattern recognition of vehicle motion behavior is proposed. The algorithm recognizes the turning behavior and speed change behavior of the vehicle by monitoring and analyzing the data change law of the linear acceleration sensor and direction sensor built in the smartphone, and requests GPS sensor positioning to record the corresponding trajectory feature points according to the pattern recognition result, so as to realize real-time online compression of vehicle trajectory. The proposed algorithm is compared with the representative trajectory compression algorithms characterized by feature point extraction. The results indicate that although it is slightly weaker than the representative trajectory compression algorithms in compression accuracy, it can compress the trajectory data online, with strong real-time performance and high calculation efficiency, which reduces the amount of network transmission data. It only requests positioning and sampling at key feature points, the results of which is able to adapt to changes in road conditions to some extent; thus it reduces the storage space of the mobile phone, and decreases the power consumption of the mobile phone.

**Key words:** Trajectory compression; Mobile phone sensor; Motion behavior pattern; Trajectory feature point

伴随着基于位置的服务 (location based service, LBS) [1] 等现代技术的快速发展, 产生了巨量用于刻画移动对象运动的时空轨迹数据, 并被广泛应用于智能交通系统的分析决策上。由于庞大的数据规模

对于时空轨迹的存储、管理和分析带来了严峻挑战, 因此时空轨迹的数据压缩就成为了轨迹大数据研究领域的一个重要问题。

基金项目: 国家自然科学基金面上项目 (41971346), 河南省自然资源厅 2020 年度省自然科技项目 (2020-165-10)  
第一作者: 赵东保 (1979-), 男, 教授, 研究方向为空间数据融合与挖掘, Email: zdongbao@126.com

时空轨迹的数据压缩方法<sup>[2]</sup>主要分为基于特征点提取的压缩<sup>[3-6]</sup>、基于路网的压缩<sup>[7-9]</sup>和基于语义的压缩<sup>[10-11]</sup>等类别。基于特征点提取的压缩方法是一类通用的轨迹压缩方法，对数据的限制要求少。基于路网的压缩方法压缩率更低，但是被约束在道路网中，需要事先将轨迹数据进行较为复杂耗时的地图匹配。基于语义的压缩多是将时空轨迹转变为文本语义信息，仅在某些场景中应用。轨迹压缩还可以分为离线压缩和在线压缩两类，离线压缩是指整个轨迹数据全部读取完毕才进行压缩，一般都是利用轨迹数据的全局特征进行静态处理。例如，经典的 DP 算法（douglas-peucker 算法）<sup>[3]</sup>就是根据中间轨迹点到全局首末轨迹点连线的垂直偏差距离来提取轨迹特征点。TD-TR 压缩算法（top-down time radio）<sup>[4]</sup>也是一种代表性离线压缩算法，其思路与 DP 算法相似，但采用时间同步欧式距离（SED）阈值代替垂直偏差距离阈值来更好地顾及轨迹的时空特性。在线压缩算法一般是基于轨迹数据的局部特征进行动态处理，以实现轨迹数据的实时压缩，方便网络传输。代表性方法如滑动窗口算法<sup>[5]</sup>、标准开放窗口（normal opening window, NOPW）算法等<sup>[4,6]</sup>，其基本思路都是从动态改变的窗口中提取特征点，以实现在线压缩。轨迹压缩过程类似于曲线化简，因此制图综合领域的经典算法<sup>[12]</sup>也具有重要参考价值，但制图综合关注的是地理要素空间特征的概括与抽象，而轨迹压缩关注的是轨迹时空特征的采集、压缩、存储和传输等。

尽管已经存在了相当数量的时空轨迹压缩方法，然而采集轨迹数据的移动设备（如智能手机等）都有存储空间和用电量的限制，在智能手机等移动设备上使用这些压缩算法无疑会面临较高耗电量和占用较大存储空间的问题。由于智能手机设备不止具有 GPS 等定位传感器，还具有其他各类传感器，近些年来，一些学者利用手机传感器在用户活动模式识别开展了较多的研究工作。例如，文献[13-17]就系统讨论了如何利用手机传感器数据识别用户的日常运动模式，如坐下、静止、步行、跑步和上下楼梯等；文献[18-20]则研究了基于手机传感器数据识别用户的出行模式，诸如，骑行、公交车、出租车、火车、地铁和轮渡等；文献[21-23]则研究了利用手机传感器识别车辆的运动模式，如急转弯、急刹车、急变道等危险驾驶行为。文献[24]对上述有关研究进行了总结归纳，对手机传感器在用户活动模式识别领域上取得的进展进行了全面综述。

虽然在轨迹压缩与基于手机传感器的用户活动模式识别领域都取得了重要进展，但是鲜有研究工作将二者相互结合，并根据双方研究特点，综合解决轨迹压缩问题。为此，本文通过智能手机内部多个低能耗传感器（如线性加速度传感器等）的相互配合作用来识别用户的运动状态变化，提出一种基于车辆运动行为模式识别的车辆轨迹数据压缩算法，只有当运动状态发生改变时才采集该时刻下的轨迹特征点坐标，以便更好地节省手机存储空间，降低能耗和提高计算效率。

## 1 算法思路

轨迹压缩的核心目标是提取轨迹的特征点，并去除冗余点。已有压缩算法都是先有原始轨迹，再从中提取特征点。但是，如果能够根据车辆的运动行为模式在轨迹的采集过程中就识别出轨迹特征点，就可以直接略过冗余点，即可实现了轨迹压缩。以下图 1 为例，蓝色点、红色点和黑色点分别代表着本次车辆出行的起止点（见①、⑩处）、变速点（见②、④、⑦、⑨处）和转弯点（见③、⑤、⑥、⑧处）这些点显然都是需要采集的轨迹特征点，而白色点则是无须采集的轨迹冗余点。为此，可以借助智能手机的多个传感器完成对车辆运动行为模式的识别。本文算法的核心思想就是通过监测智能手机中低能耗的线性加速度传感器和方向传感器的数据变化来共同实时判断车辆运动行为模式是否发生变化，运动行为模式包含直线行驶、左右转弯、掉头、启动、制动、变速等，若车辆运动行为模式变化则使用 GPS 传感器记录当前点坐标，若车辆运动状态处于平稳不变时，则不采样，从而减少定位请求，以此完成省内存、低能耗的实时轨迹特征点采集工作，达到在线轨迹压缩的目的。




图 1 轨迹特征点采集示意

Fig. 1 Collection of trajectory feature points

## 2 基于手机传感器的车辆运动行为模式识别及轨迹特征点采集

为了尽可能地降低能耗，本文只借助线性加速度传感器和方向传感器识别车辆的运动行为模式。线性加速度计输出的是手机 X、Y、Z 三轴（如图 2 所示）的加速度值，且除去了重力加速度在三个轴上的分量。方向传感器的数据分别为方位角、俯仰角和翻滚角，其中方位角为手机绕 Z 轴旋转时，Y 轴正方向与地磁场北极方向的夹角；俯仰角为手机绕 X 轴旋转时，Y 轴正方向与水平方向的夹角；翻滚角为手机绕 Y 轴旋转时，X 轴正方向与水平方向的夹角。在传感器数据采样过程中需保持手机自身姿态固定不变，但对初始姿态不做限制，可以任意摆放。在获取不同运动行为模式的传感器数据后，通过对数据的分析来找到相应运动模式下传感器的数据变化规律，以此作为运动模式识别的判断指标，并采集相应轨迹特征点。




图 2 手机三轴坐标系

Fig. 2 Three-axis coordinate system of mobile phone

## 2.1 基于变速模式识别采集轨迹特征点

变速模式识别主要识别车辆的启动制动行为及车辆行驶过程中的急加减速行为，下图 3 为手机线性加速度计在车辆启动和制动时各轴的数据变化情况。可以看出，车辆静止、加速启动、正常行驶和制动停车过程中，线性加速度的区分明显。在车辆静止候车状态时，三轴加速度围绕  $0\text{m/s}^2$  上下有规律波动；当车辆加速启动时，Y 轴加速度数据从零向正值快速变大，后加速结束又趋于零附近；当车辆正常匀速行驶时，三轴加速度围绕零值上下波动且幅度大于车辆静止时；当车辆制动停车时，Y 轴加速度数据从零值附近向负值快速变大，





图 3 车辆启动制动时线性加速度计数据变化

Fig. 3 Changes in linear accelerometer data during vehicle starting and braking

变速特征点的识别方法：车辆的加减速行为为反应在加速度序列的增减趋势变化上，那么加速度的时间数据序列就不是围绕某一值上下波动的平稳状态而是值不断上升或下降的非平稳状态，本文采用 M-K 非参数趋势检验法<sup>[25]</sup>来识别加速度时间序列的变化趋势，该方法不需要样本数据遵循一定分布且不受少数异常值影响，故在加速度序列的趋势判断上具有较高的准确率。

设加速度时间序列数据为  $\{x_1, x_2, \dots, x_n\}$ ，是独立、随机同变量分布样本，对于所有的  $x_i$ ， $x_j$ ， $i, j \leq n$  且  $i \neq j$ ，计算统计量  $S$ ：

$$S = \sum_{i=1}^{n-1} \sum_{j=i+1}^n \text{sgn}(x_j - x_i) \quad (1)$$

$$\text{sgn}(x_j - x_i) = \begin{cases} 1, & x_j - x_i > 0 \\ 0, & x_j - x_i = 0 \\ -1, & x_j - x_i < 0 \end{cases} \quad (2)$$

式中：

$\text{sgn}()$  为符号函数，且当  $n \geq 10$  时（本文  $n = 40$ ），统计量  $S$  近似服从正态分布，其均值为 0，方差为：

$$\text{Var}(S) = n(n-1)(2n+1)/18 \quad (3)$$

构造标准正态分布统计量  $U$ ：

$$U = \begin{cases} \frac{S-1}{\sqrt{\text{Var}(S)}} & , S > 0 \\ 0 & , S = 0 \\ \frac{S+1}{\sqrt{\text{Var}(S)}} & , S < 0 \end{cases} \quad (4)$$

对  $U$  进行双边检验，在给定的置信水平  $\alpha$  上，若  $|U| \geq U_{1-\alpha/2}$ ，则原假设是不可接受的，即在  $\alpha$  置信水平上，加速度时间序列存在明显的上升或下降趋势。当  $U > 0$  时，则为上升趋势，为车辆的加速运动，反之则为车辆的减速运动；若  $U$  的绝对值大于或等于 1.28、1.64 和 2.32，表示该样本通过置信度分别为 90%、95% 以及 99% 的显著性检验水平，为确保对变速运动模式识别的敏感性，本文采用置信度为 90% 时的  $U$  值检验，即  $|U| \geq 1.28$ 。由于该阈值是对



加速度值相对变化趋势的分析,是统计意义的参数,而非绝对量的加速度值,这有助于避免测量精度的影响,独立于手机型号。

## 2.2 基于转向模式识别采集轨迹特征点

车辆的转向模式识别主要是区分直线行驶和转弯行驶,当判断处于转弯行驶时则需要采集转向点坐标,当判断处于直线行驶则仅需要采集变速点即可。如图 4 所示为车辆行驶过程中手机方向传感器在发生不同转向行为时各个轴的数据变化情况。可以看出,车辆在转向时,俯仰角和翻滚角均保持平稳未发生明显趋势变化,而方位角则发生了剧烈的上升和下降变化,在车辆右转时,方位角逐渐增大,约为  $90^\circ$ ,反之左转时则逐渐减小,也约为  $90^\circ$ 。

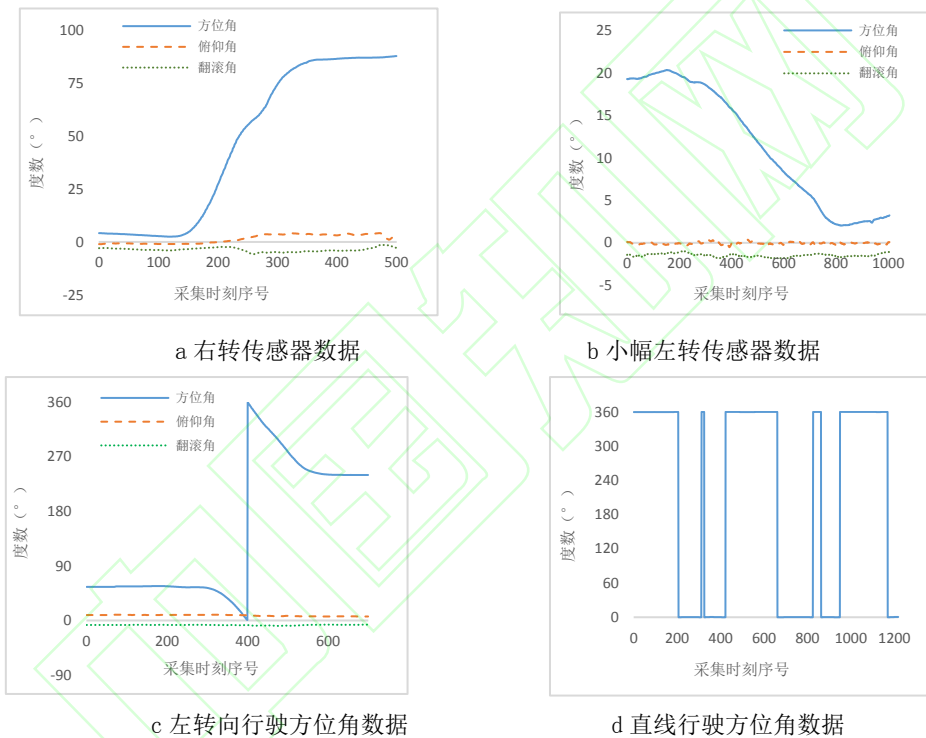


图 4 车辆转向行驶时方向传感器三轴数据变化

Fig. 4 Changes in three-axis data of direction sensor during vehicle turning

转向特征点识别方法: 本文将车辆转向行为分为左右转弯、掉头等幅度较大的短距离转弯和转向幅度较小的长距离转弯。通常一个左右转弯幅度大概在  $80^\circ$  到  $120^\circ$  之间,当转弯幅度在  $40^\circ$  到  $60^\circ$  时,车辆大致恰好位于道路的交叉点位置,故本文中当转向角度累计到  $40^\circ$  时才采集一个转向特征点,以避免冗余采集。但对于小幅度的长距离转弯,若等到转向角度 $\alpha$ 累计到  $40^\circ$  再采集特征点,此时车辆可能已经行驶了较长距离,故通过设置采样时间间隔阈值  $T$  来控制累计转向角小于  $40^\circ$  的情况下的转向特征点采集。

同时从图 4a 和 4b 可以看出,当车辆在做幅度较大、距离较短的转弯时用时较短且方位角曲线斜率较大,相应的车辆左转或掉头亦是如此,而车辆在做幅度较小、但距离较长的缓慢转弯时用时较长且方位角曲线斜率较小。此外,由于方向传感器中方位角的输出范围为  $0^\circ \sim 360^\circ$ ,会存在如图 4c、4d 所示的方位角数据突变情况,多数情况下发生在车辆的转向和掉头行为中,有时也发生在车辆的直线行驶中(行驶方向正好为  $0^\circ$  或  $360^\circ$ )。为此在方向传感器数据的处理部分也需要考虑该特殊情况。总体而言,方向传感器的方位角数据所反映出的变化特征对转向行为具有良好的识别性。




图 5 基于方位角的车辆转向特征点采集示意

Fig. 5 Acquisition of vehicle steering feature points based on azimuth angle

以上图 5 为例介绍本算法转向特征点具体采集过程。根据方位角的变化幅度及曲线变化率，假设图中的 AC、EF 和 HI 段对应轨迹的直线段，CE、FH 段对应轨迹的转向段，且 CE 段为大幅度短距离转弯，FH 段为小幅度长距离转弯。初始时设数据采集序列第一点 A 为锚点  $(X_{\text{锚点}}, Y_{\text{锚点}})$ ，序列第二点为浮动点  $(X_{\text{浮动}}, Y_{\text{浮动}})$ ，浮动点代表当前时刻的采集点，累计转向角  $\alpha$  初值为 0。首先采用式 (5) 判断车辆行驶状态，当  $\alpha_1 \leq 3^\circ$  时，认为车辆为直线行驶状态（如 AC 段），此过程不采集转向点，若该直线部分存在变速点（假如 B 点），则采集该坐标并将锚点 A 移动到当前点 B，后继续采集新时刻的方位角数据；当  $\alpha_1 > 3^\circ$  时，车辆视为转向行驶（如 CE 段），采集该转向点坐标并将锚点 B 移动到点 C，后采用式 (6) 计算累计转向角  $\alpha$ ，当  $|\alpha| \geq 40^\circ$ ，则采集相应坐标（如点 D），并令  $\alpha = 0$ ，后将锚点 C 移动到 D 点，同理，假设图中 E 点为下一个  $\alpha$  到达  $40^\circ$  的转向特征点。EF 段判断仍采用与 AC 段相同的方法，假设识别出转向点 F；FH 段则增加一个采样时间间隔阈值  $T$  判断，当累计转向角  $|\alpha| < 40^\circ$ ，但  $\Delta T = T$  时，则采集该坐标（如点 G、H），该阈值保证了长距离缓慢转弯的轨迹精度。

$$\alpha_1 = \text{Max}\{Y_{\text{锚点}}, \dots, Y_{\text{浮动}}\} - \text{Min}\{Y_{\text{锚点}}, \dots, Y_{\text{浮动}}\} \quad (5)$$

$$\alpha = \begin{cases} |Y_{\text{浮动}} - Y_{\text{锚点}}|, & \alpha_1 \neq 360^\circ \\ 360^\circ - |Y_{\text{浮动}} - Y_{\text{锚点}}|, & \alpha_1 = 360^\circ \end{cases} \quad (6)$$

$$\Delta T = X_{\text{浮动}} - X_{\text{锚点}} \quad (7)$$

### 3 本文轨迹实时在线压缩算法步骤

本算法按照 20Hz，即 0.05s 的采样频率，对手机内置方向传感器和线性加速度计进行数据采集和分析以实时在线提取特征点，实现轨迹压缩，程序流程图如图 6 所示，具体过程如下：

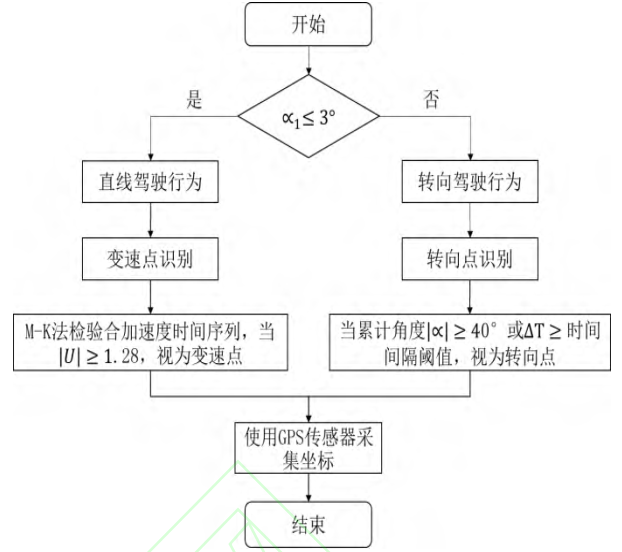


图 6 本文算法轨迹压缩程序流程

Fig. 6 Flow chart of vehicle trajectory data compression of proposed algorithm

设  $P = \{P_i\}$ ,  $(i \in 1 \cdots n)$  为传感器数据集，其中， $P_i(X, Y, Z)$  为第  $i$  次采集的数据点， $X, Y, Z$  分别表示采集时刻、方向传感器的方位角值和三轴合线性加速度值。初始时， $P_{\text{start}}$  为数据序列的第一点，记为锚点， $P_{\text{cur}}$  为数据序列的第二点，记为浮动点。设定时间间隔阈值为  $T$ ，如 5s、10s 等。则步骤如下：

步骤一：以初始时刻为计算起点，令  $\text{Max} = Y_{\text{start}}$ ,  $\text{Min} = Y_{\text{start}}$ ；此后当  $Y_{\text{cur}} > \text{Max}$  时，令  $\text{Max} = Y_{\text{cur}}$ ，当  $Y_{\text{cur}} < \text{Min}$  时，令  $\text{Min} = Y_{\text{cur}}$ ，否则  $\text{Max}$ 、 $\text{Min}$  不变，以此类推；累积转弯角度  $\alpha$  初始值为零。

步骤二：采用式 (4)、(5) 分别计算正态统计变量  $U$  和转向幅度  $\alpha_1$ ，并分为两种情况。

情况 1. 当  $\alpha_1 \leq 3^\circ$  时，视为直线行驶，后根据  $U$  值继续判断：

(1) 若  $|U| < 1.28$  时，车辆处于匀速直线行驶或静止不动状态，则保持锚点  $P_{\text{start}}$  不动，并继续采集新的传感器数据点  $P_{\text{cur}}$ ，回到步骤一。

(2) 若  $|U| \geq 1.28$  时，车辆发生变速行为，当  $\Delta T \geq$  时间间隔阈值  $T$ ，则采集当前坐标点，并移动锚点  $P_{\text{start}}$  到当前点  $P_{\text{cur}}$ ，令  $\text{Max} = Y_{\text{cur}}$ ,  $\text{Min} = Y_{\text{cur}}$ ，后继续采集新的传感器数据点，重回步骤一。

情况 2. 当  $\alpha_1 > 3^\circ$  时，视为转向行驶，则采集该转向点坐标，并移动锚点  $P_{\text{start}}$  到当前点  $P_{\text{cur}}$ ，且令  $\alpha = 0$ ,  $\text{Max} = Y_{\text{cur}}$ ,  $\text{Min} = Y_{\text{cur}}$ ；后采用式 (6) 计算累计转向角  $\alpha$ ，当  $|\alpha| \geq 40^\circ$  时，采集该点坐标，若在  $\Delta T = T$  期间内，始终未出现  $|\alpha| \geq 40^\circ$  的转向点，则在该时间段结束时也采集当前点坐标，并以

相同方式移动锚点到浮动点处，且令 $\alpha = 0$ ， $Max = Y_{cur}$ ， $Min = Y_{cur}$ ；重回步骤一。

重复循环上述步骤直到数据采集完毕。

## 4 算法性能评价标准

轨迹压缩算法的性能可从空间距离偏差、时空距离偏差、压缩率、实时性、压缩耗时等指标进行综合评价，各指标含义如下：

**空间距离偏差：**令 $P = \{P_1, P_2, \dots, P_n\}$ 为按固定采样间隔采集的原始轨迹， $L = \{L_1, L_2, \dots, L_k\}$ 为压缩后保留的轨迹特征点，原始轨迹点的坐标表示为 $(X_{P_i}, Y_{P_i})$ ， $(i = 1, 2, \dots, n)$ ，压缩后轨迹点的坐标表示为 $(X_{L_i}, Y_{L_i})$ ， $(i = 1, 2, \dots, k)$ ，将原始轨迹点垂直投影到相应的化简线段上，如下图 7a 中， $P_3$ 的垂直投影点为 $Q_3$ ，将原始轨迹中任意点 $P_i$ 与其对应点 $Q_i$ 的偏差距离记为 $D_i$ ， $(i = 1, 2, \dots, n)$ ，则该偏差距离之和的平均值即为空间距离平均偏差（Average Euclidean Distance Error, AEDE）。




图 7 压缩精度指标的计算

**时空距离偏差：**时空距离偏差不仅考虑了轨迹点的位置而且还加入了时间属性，如图 7b 所示， $P_3$ 的对应点仍是 $Q_3$ ，但该对应点是对时间信息进行线性插值得到的。在图 7b 的原始轨迹中，根据从起始点到任意点 $P_i$ 所经历的时间与总的时间之比，再在相应的化简线段上进行线性插值即可得到 $P_i$ 的对应点 $Q_i$ ，根据二者的偏差距离就可得到时空距离偏差，继而得到时空距离平均偏差（Average Synchronized Euclidean Distance Error, ASEDE）。

**压缩率 R：**压缩后保留轨迹点特征数 $k$ 与原始轨迹点总数 $n$ 的比值，表示为：

$$R = \frac{k}{n} \times 100\% \quad (8)$$

**实时性：**实时性是指采集获取轨迹点后，需要多长时间方能确定该点是否是特征点。


**压缩耗时：**在规定的压缩率下，完成对一条轨迹的压缩所消耗的时间。

一般而言，很难有一种压缩算法在所有性能指标上全部占优，需要结合应用场景进行选择。当看重压缩精度指标时，通常离线压缩算法压缩精度最好，当看重实时性时，则可采用在线压缩算法。


## 5 实验验证与分析

### 5.1 实验环境情况

本次实验采用四种不同型号的智能手机（MI8、MI8 Lite、HONOR 20 和 HUAWEI P20）分别采集四种路况下的轨迹数据。手机均放置于车体内部，且对初始姿态不做要求，但应保证行驶过程中保持稳定。首先对三种传感器耗电情况进行实际测试（以 MI 8 手机为例）。算法中性线性加速度传感器和方向传感器的采样间隔为 0.05s，GPS 传感器为 1s，采用消耗电池的容量值（mAh）代表传感器的耗电量，实测结果如图 8a 所示。线性加速度传感器，方向传感器和 GPS 定位传感器每小时耗电约为 1mAh、2mAh 和 40mAh，GPS 传感器的耗电量远远高于其他两种传感器。图 8b 是采用百度地图 API 的定位功能实验测得的在不同采样间隔下手机耗电量情况，随着定位请求采样间隔的增加，手机耗电量稳步降低。可见合理增大采样间隔，减少请求定位次数有助于一定程度上降低手机的能耗。



a 手机内置传感器耗电量



b 不同间隔下手机耗电量

图 8 手机内置传感器耗电情况

Fig. 8 Power consumption of built-in sensors in mobile phones

## 5.2 实验轨迹压缩结果情况

根据不同路况属性分成四种类型进行算法测试：

- ①高速道路：道路平滑顺直，路况好，车辆行驶速度快；
- ②山区道路：道路盘绕山体，蜿蜒曲折坡陡弯急；
- ③城郊道路：路况稍显复杂，存在个别颠簸路

段，行驶速度较快；④市区道路：车辆时速较慢，各种交通信号灯和交通堵塞，走走停停。如图 9 所示，图中包含了四种路况的原始轨迹以及本文压缩算法提取的轨迹特征点。时间间隔阈值设为 1 分钟，可以看出，压缩后的特征点大多都是时空轨迹三维曲线的关键转折点。

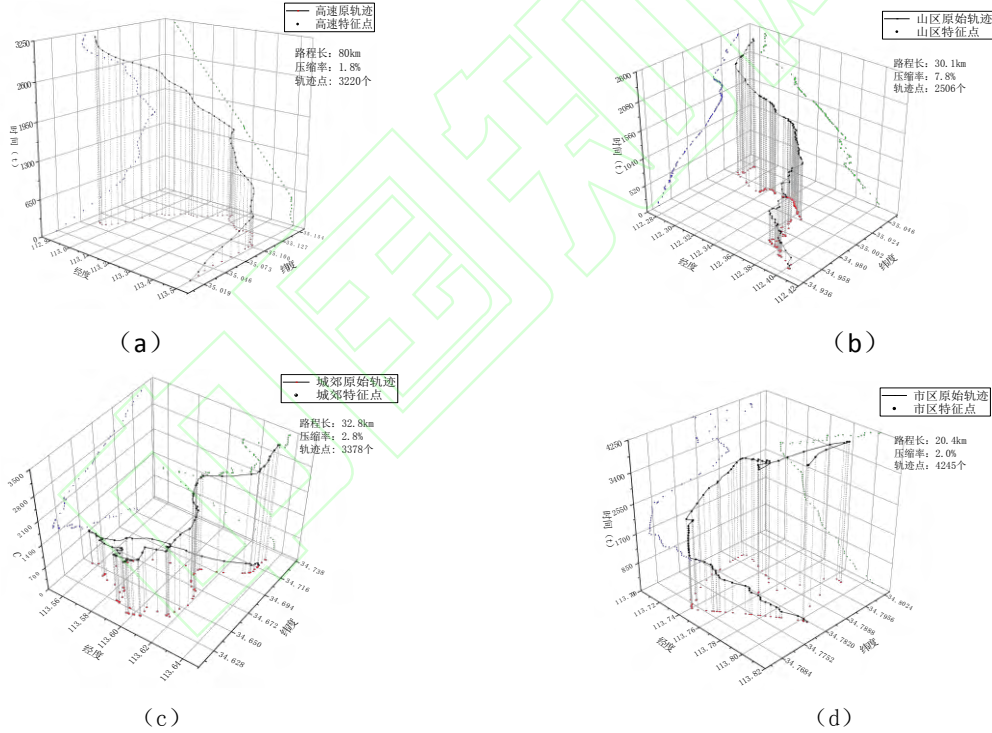


图 9 4 种不同类型的实测轨迹路线图及其压缩结果

Fig. 9 Compression results of four different types of experimental vehicle trajectories

## 5.3 实验结果分析与评价

本文算法是基于特征点识别的轨迹压缩算法，将其与同类型代表性轨迹压缩算法进行全面对比。

### 5.3.1 与固定间隔采样的实验对比

采用本文算法对四种路况下的轨迹进行压缩，其时间间隔阈值  $T$  分别设置为 5s、10s、15s 和 20s。在保证相同压缩率的情况下，与固定时间间隔采样

进行空间距离平均偏差 (AEDE) 和时空距离平均偏差 (ASEDE) 的精度对比。为保证压缩率一致，可根据图 10e 中本文算法在不同路况下的压缩率换算出固定时间间隔采样所对应的阈值。如在本文算法时间间隔阈值  $T$  分别为 5s、10s、15s 和 20s 时，山区路段对应的固定时间间隔采样阈值应为 4s、8s、11s



和 15s，高速路段对应的则为 6s、10s、15s 和 20s，其它路况可同理计算得出。

实验结果如图 10a、b、c、d 所示，可以看出随着时间间隔阈值的增大，不同路段的压缩精度愈来愈差，而在这种趋势下，本文算法的时空距离偏差和空间距离偏差始终小于固定间隔采样的相应值，且随着采样间隔的增大，这种优势有增大趋势。此外，从图 10e 中可以看出在同样的采样时间间隔阈

值下，本文算法对山区路段、城郊和市区路段、高速路段压缩率由高到低，表明了本文算法对不同路况具有一定程度的适应性。由于本算法借手机传感器可以实时识别并采集轨迹中的关键转向点和变速点，保证了轨迹的空间几何形态和时间特征，因此在相同压缩率下，本文算法在时空精度和空间精度都优于固定间隔采样。

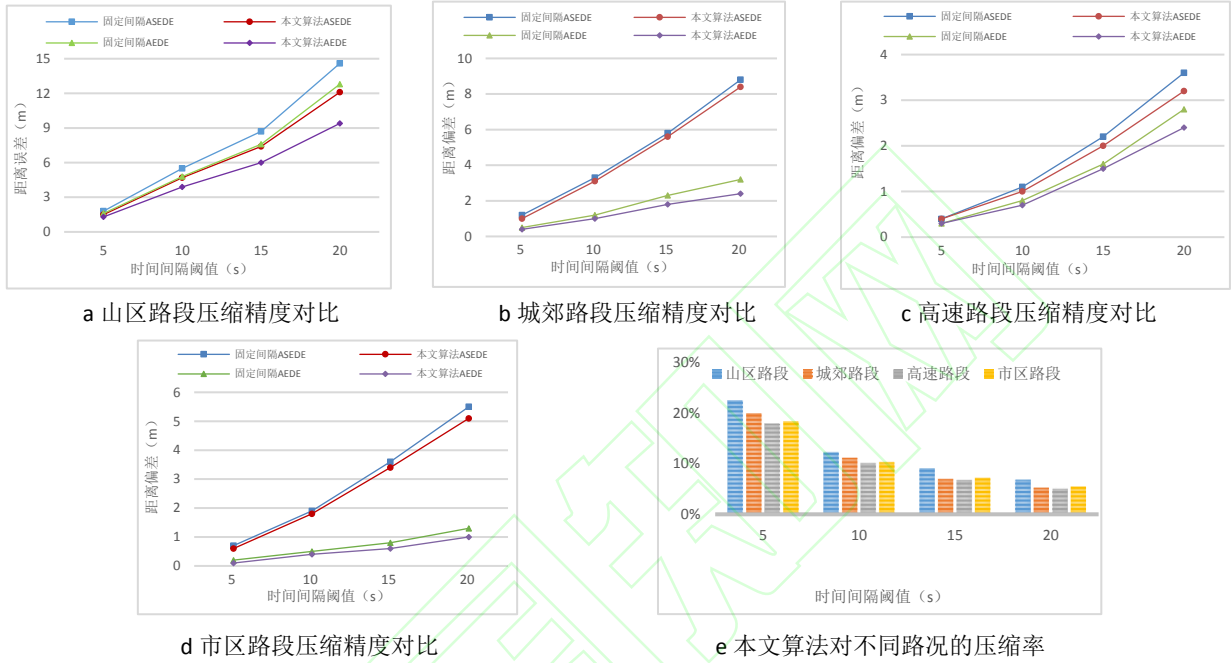


图 10 本文算法与固定间隔采样的压缩精度对比

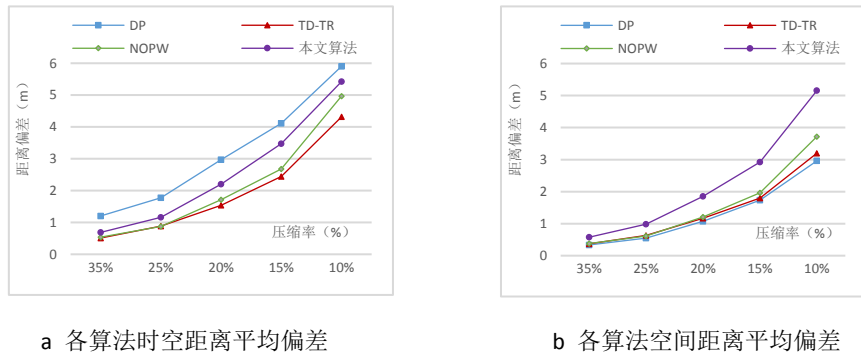
Fig. 10 Comparison of compression accuracy between proposed algorithm and fixed interval sampling


### 5.3.2 与代表性算法的实验对比

将本文算法进一步和代表性在线压缩 NOPW 算法及离线压缩 DP 算法、TD-TR 算法进行实验对比，以路况最复杂的山区路段为例，结果如图 11 所示。


从图 11a、b 中可以得出本文算法的时空压缩精度强于 DP 算法，但弱于 TD-TR 算法和 NOPW 算法，在压缩率最低时，本算法的时空距离平均偏差比在

线 NOPW 算法大约 0.5 米；本文算法的空间压缩精度弱于其他三种算法，在压缩率最低时，其空间距离平均偏差比在线 NOPW 算法大约 1.4 米，这表明本文算法在压缩精度方面不如代表性算法，但总体相差也不大。尽管本文算法压缩精度稍欠不足，但在其他性能指标上则占优。





c 各算法压缩耗时分析



d NOPW 算法的平均延迟时间

图 11 本文算法与代表性算法的压缩实验对比

Fig.11 Comparison of compression experiments between proposed algorithm and representative algorithms

首先是压缩耗时少，图 11c 是各算法压缩耗时对比，可以看出压缩率在 25% 以下，本文算法的压缩总耗时都最少，且随着压缩率减小而逐步降低，而 NOPW 算法的耗时却随着压缩率的降低逐渐增大，相比其它算法其耗时明显偏大，通常轨迹压缩的压缩率都是相当低的，这影响了其适用范围和普适性。

其次是实时性强，本文算法相较于 DP、TD-TR 等离线压缩算法可以实时在线地压缩轨迹，根据加速度传感器和方向传感器的数据处理，可以立刻在当前秒判定该轨迹点是否是特征点。NOPW 尽管是在线压缩算法，但实时性有延迟。图 11d 是针对每秒采样一次的山区路段，NOPW 算法在不同压缩率下判断得出读入的轨迹点是否是特征点的平均延迟时间，可以看出其在 5% 压缩率下，甚至要延迟十几秒，方能确定特征点，这在某些智能交通应用场景是重要不足。

最后是 GPS 请求定位次数少，上述各代表性轨迹压缩算法需采集所有原始轨迹点方能完成轨迹压缩，请求定位次数就是所有轨迹点个数。而本文算法只对轨迹的关键点才请求定位并进行坐标采集，GPS 的请求定位次数仅仅只是保留下来的特征点数目。当需要对大规模浮动车（如出租车等）轨迹进行特征点采集并实时上传到服务器时，本文算法由于实时性强，无延迟且请求次数最少，显然有助于减弱对 GPS 传感器的使用强度和减少数据的网络传输量，有利于定位设备的节能。

## 6 结 论

本文通过监测分析手机中低能耗的线性加速度传感器和方向传感器的数据变化，来识别车辆的运动行为模式，并据此请求采集行驶过程中的轨迹特征点，从而实现车辆轨迹的实时在线压缩。将本文算法与代表性基于特征点提取的轨迹压缩算法进行实

验对比，得出以下结论：本文算法在时空距离偏差上全面优于固定时间间隔采样法和 DP 算法，但弱于 TD-DR 算法和 NOPW 算法。尽管在压缩精度上稍欠不足，但却具有综合优势。首先，本文算法是在线压缩算法，实时性强，无延迟，压缩耗时少，对手机存储空间占用少；其次，本文算法仅在关键特征点处才请求定位，减少了数据的网络传输量和对流量的消耗，减弱了对 GPS 传感器的使用强度，有助于一定程度上降低手机能耗。最后，本文算法对不同路况具有一定程度的适应性且算法所用的时间间隔阈值也便于普通用户理解。总之，本文算法是一个兼顾了多项指标的车辆轨迹实时在线压缩算法，适用于面向大众用户的轨迹类场景应用。

## 参考文献

- [1] Ray S, Blanco R, Goel A K. Supporting Location-Based Services in a Main-Memory Database[C]. IEEE International Conference on Mobile Data Management. IEEE, 2014.
- [2] Sun P, Xia S, Yuan G, Li D. An Overview of Moving Object Trajectory Compression Algorithms[J]. Mathematical Problems in Engineering, 2016, (2016-5-8), 2016, 2016(pt.5):1-13., 2016
- [3] Douglas D H, Peucker T K. Algorithms for the Reduction of the Number of Points Required to Represent a Digitized Line or Its Caricature[J]. Cartographica, 1973, 0(2):112-122.
- [4] Meratnia N, Rolf A. Spatiotemporal Compression Techniques for Moving Point Objects[J]. Advances in Database Technology - EDBT 2004 Volume 2992 of the series Lecture Notes in Computer Science Springer Berlin Heidelberg, 2004, 2992:765-782.
- [5] Cao X, Cong G, Jensen C S. Mining significant semantic locations from GPS data[J]. Proceedings of the VLDB Endowment, 2010.
- [6] Keogh E J, Chu S, Hart D M, Pazzani M J. An online algorithm for segmenting time series. In ICDM, 2001:289-296.

- [7] 唐炉亮,刘章,杨雪,阚子涵,李清泉,董坤.符合认知规律的时空轨迹融合与路网生成方法[J].测绘学报,2015,44(11):1271-1276+1284.
- [8] Sandu Popa I, Zeitouni K, Oria V, Kharrat A. Spatio-temporal Compression of Trajectories in Road Networks[J]. *GeoInformatica*, 2015,19(1), 117–145
- [9] Song R, Sun W, Zheng B, Zheng Y. PRESS: A Novel Framework of Trajectory Compression in Road Networks[C]. *Proceedings of the VLDB Endowment*, 2014,7(9): 661–672
- [10] Chongming G, Yi Z, Ruizhi W, Qinli Y, Junming S. Semantic trajectory compression via multi-resolution synchronization-based clustering[J]. *Knowledge-Based Systems*, 2019, 174.
- [11] Su H, Zheng K, Zeng K, et al. Making Sense of Trajectory Data: A Partition and Summarization Approach[C]. *Proceedings of the 31st IEEE International Conference on Data Engineering*. IEEE, Seoul, South Korea, 2015: 963 - 974
- [12] 武芳,巩现勇,杜佳威.地图制图综合回顾与展望[J].测绘学报,2017,46(10):1645-1664.
- [13] Duarte F, André Lourenço, Abrantes A. Classification of Physical Activities Using a Smartphone: Evaluation Study Using Multiple Users[J]. *Procedia Technology*, 2014, 17:239-247.
- [14] Alman A, Armin L, Zulkifli T. Pattern Recognition of Human Activity Based on Smartphone Data Sensors Using SVM Multiclass[C]. *1st International Conference on Science and Technology, ICOST 2019, 2-3 May, Makassar, Indonesia*, 2019.
- [15] Cagatay C, Selin T, Elif P, Guner K. On the use of ensemble of classifiers for accelerometer-based activity recognition [J]. *Applied Soft Computing*, 2015, 37: 1018-1022.
- [16] Hasegawa T. Smartphone Sensor-based Human Activity Recognition Robust to Different Sampling Rates[J]. *IEEE Sensors Journal*, 2021, 21(5): 6930 – 6941.
- [17] Xiaou L, Zhiyong Z, Jiajia W, Yichao X. Human Posture Detection Method Based on Wearable Devices[J]. *Journal of Healthcare Engineering*, 2021, Article ID 8879061.
- [18] Guvensan M A, Dusun B, Can B, Turkmen H I. A novel segment-based approach for improving classification performance of transport mode detection[J], *Sensors (Switzerland)*, 2018, 18(1) 87-105.
- [19] 姚振兴. 基于手机传感器数据的个体交通出行链信息采集方法研究[D].西南交通大学, 2018.
- [20] 龚彦云. 基于深度学习的出行模式识别技术研究[D].北京邮电大学, 2018.
- [21] 谢非,汪壬甲,沈世斌,孙蕊,张斌,刘锡祥.基于手机惯性传感器与多特征 CNN 的驾驶行为识别算法[J].中国惯性技术学报, 2019, 27(03): 288-294.
- [22] 杜文文. 基于智能手机传感器的人车状态持续感知与危险驾驶识别[D].中国科学技术大学, 2019.
- [23] 周后飞. 基于移动终端的异常驾驶行为及碰撞事故识别技术研究[D].重庆交通大学, 2016.
- [24] Marcin Straczekiewicz, Jukka-Pekka Onnela. A systematic review of human activity recognition using smartphones[J]. 2019 <https://arxiv.org/abs/1910.03970v1>
- [25] Kendall M G. Rank correlation methods[M]. London: Charles Griffin Company, 1975.